VL 04 · Wissen abrufen

File-based Retrieval und RAG: Wie das Modell erfährt, was es nie gelernt hat

Prof. Dr. Pascal Laube · HTWG Konstanz · WS 2026/27

Unser Assistent weiß nur, was im Prompt steht

Der Campus-Assistent aus Übung 2 (`assistent.v1` , `llama3.2:3b`) kennt vier Fakten: Bibliothek, Mensa, Prüfungsanmeldung, Kopierraum. Zwei echte Antworten, gemessen am 23.10.:

FRAGE
Ich bin am Tag meiner Klausur krank. Was muss ich tun?

ANTWORT DES MODELLS
Leider ist es nicht möglich, deine Klausur abzugeben. Du solltest dich an das Prüfungsteam wenden und deine **Abmeldung im HISinOne** anfordern.

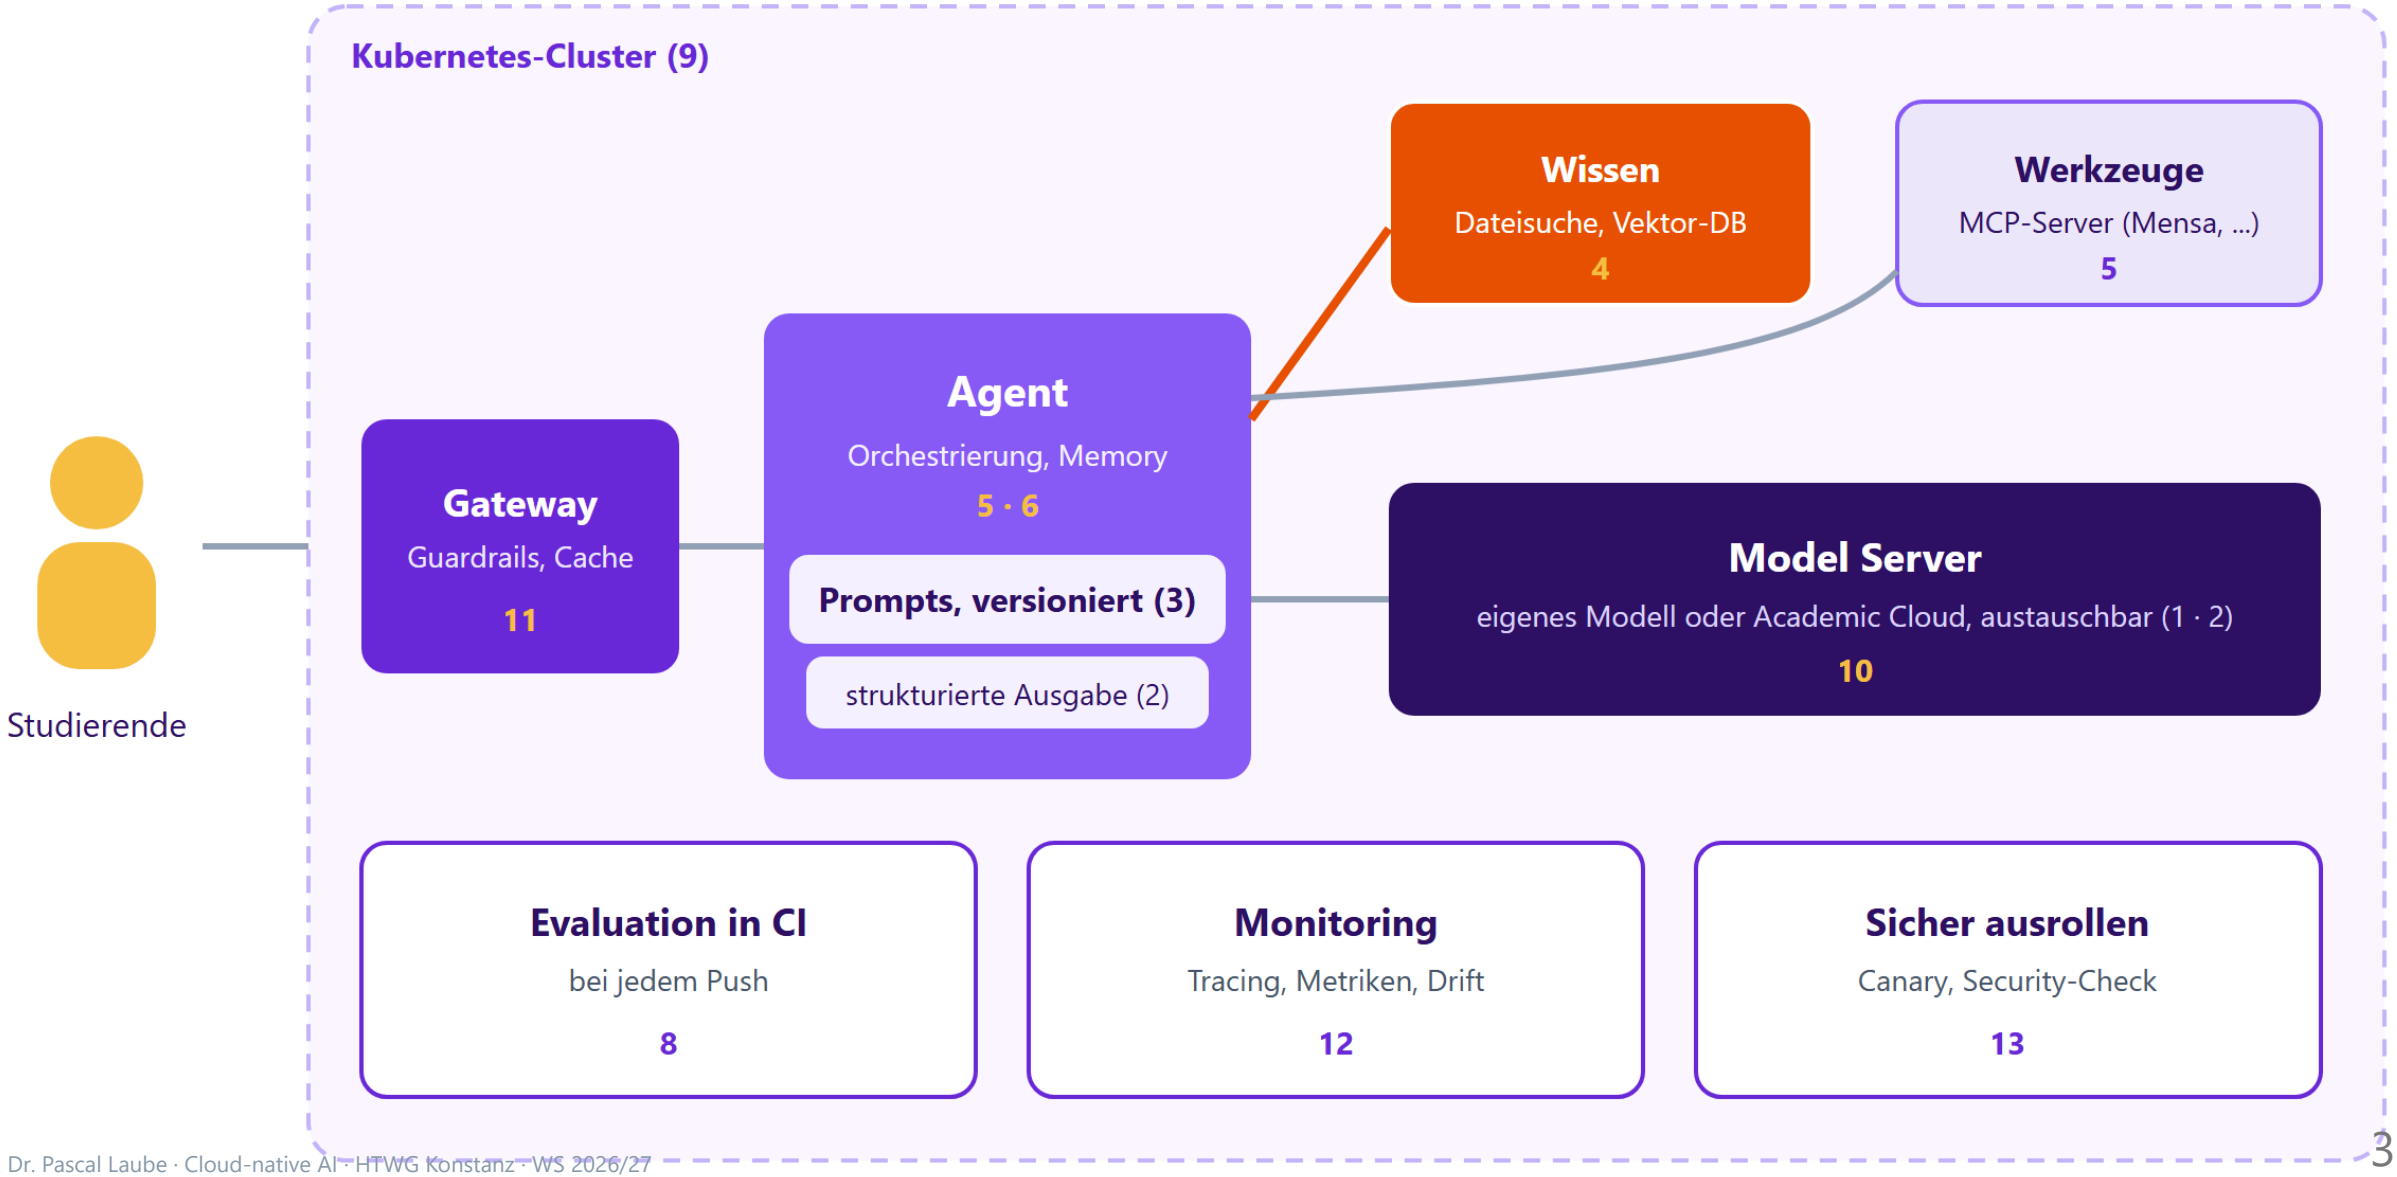
FRAGE
Wo kann ich mein Auto abstellen?

ANTWORT DES MODELLS
Leider gibt es **keine spezielle Abstellfläche** für Autos auf dem Campus der HTWG Konstanz. […] Es gibt einige öffentliche Parkhäuser in der Nähe.

Frage an euch: Beides klingt hilfsbereit und ist falsch. Die Abmeldung endet sieben Tage vor der Prüfung, und es gibt zwei Parkplätze. Woher soll das Modell das wissen?

Heute kommt eine Schicht dazu: Wissen abrufen

VL 4 · die Zahlen sind die Vorlesungen · orange ist die Schicht von heute



Drei Wege, Wissen in den Kontext zu bringen

Für Übung 2 hat der Assistent eine Wissensbasis bekommen: **21 Markdown-Dateien** von `bibliothek.md` bis `pruefungsordnung.md`, alle ausgedacht. Heute vergleichen wir:

0 · Alles mitgeben

Die ganze Wissensbasis steht in jedem Prompt. Keine Suche.

1 · Nach Zeichen suchen

File-based Retrieval: `grep` findet die passenden Dateien, wenn die Frage da ist.

2 · Nach Bedeutung suchen

RAG: Embeddings und eine Vektordatenbank finden ähnliche Abschnitte.

Begriffe und Reihenfolge folgen Huyen, *AI Engineering*, Kapitel 6, den Cloud-Teil liefern Huß und Zonca, *Generative AI on Kubernetes*, Kapitel 8. Ab 10:45 seid ihr dran, im Retrieval-Labor.

Weg 0: Bei 21 Dateien gewinnt, wer gar nicht sucht

	alles im Prompt
Eingabe-Tokens pro Frage	**3.904**
erste Antwort	55 bis 63 s
jede weitere Antwort	**8 s** im Schnitt
richtige Antworten	**14 von 14**

Gemessen mit `llama3.2:3b` auf dem Laptop, ohne GPU.

Warum wird es schneller?

Der **Prompt-Cache**: Die Wissensbasis steht vorne und ändert sich nie, nur die Frage am Ende ist neu. APIs berechnen gecachte Tokens deutlich günstiger.

Faustregel

Unter etwa 200.000 Tokens (rund 500 Seiten) die Wissensbasis einfach komplett mitgeben (Anthropic, zitiert bei Huyen).

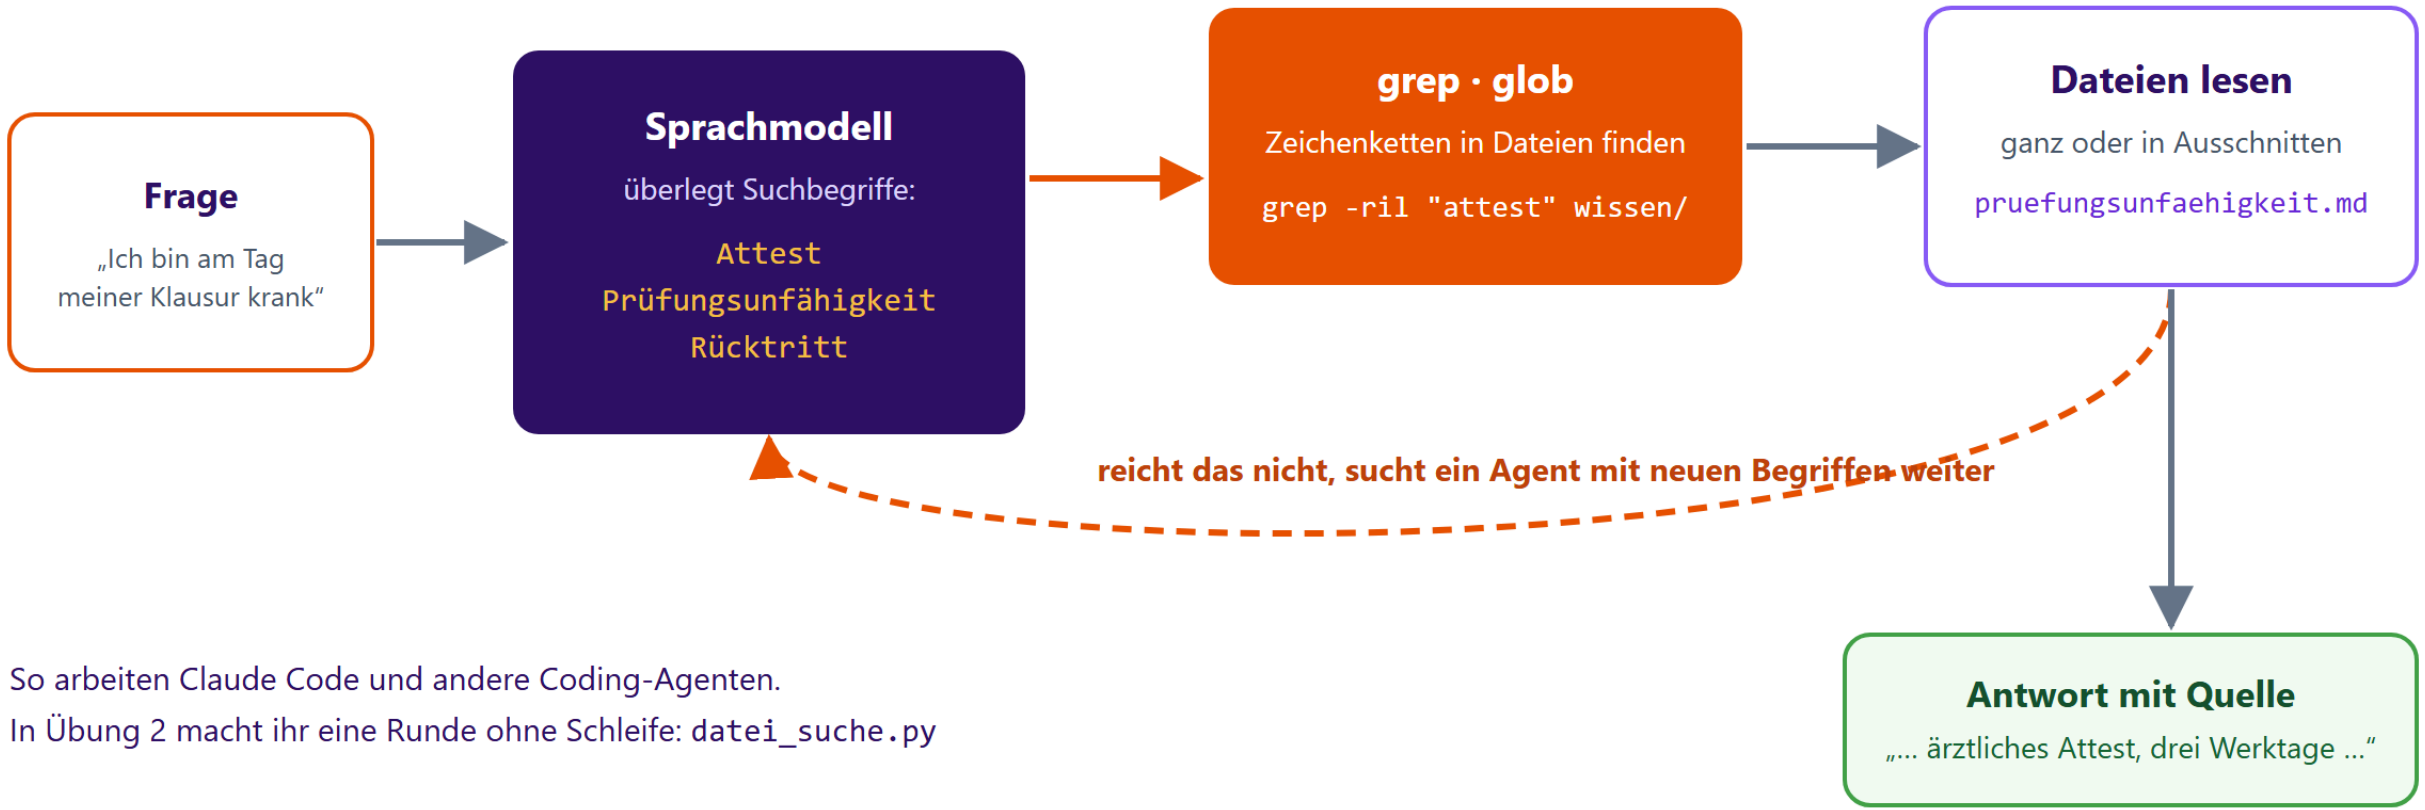
Warum dann überhaupt suchen? Daten wachsen schneller als Kontextfenster, jedes Token kostet, und in langen Kontexten geht Wissen verloren (Lost in the Middle, VL 3).

1 · File-based Retrieval

Suchen, wenn die Frage da ist, ohne Index

File-based Retrieval: suchen, lesen, nochmal suchen

kein Index, keine Embeddings · gesucht wird erst, wenn die Frage da ist (just in time)



So arbeiten Claude Code und andere Coding-Agenten.
In Übung 2 macht ihr eine Runde ohne Schleife: `datei_suche.py`

Claude Code hat den Vektorindex wieder ausgebaut

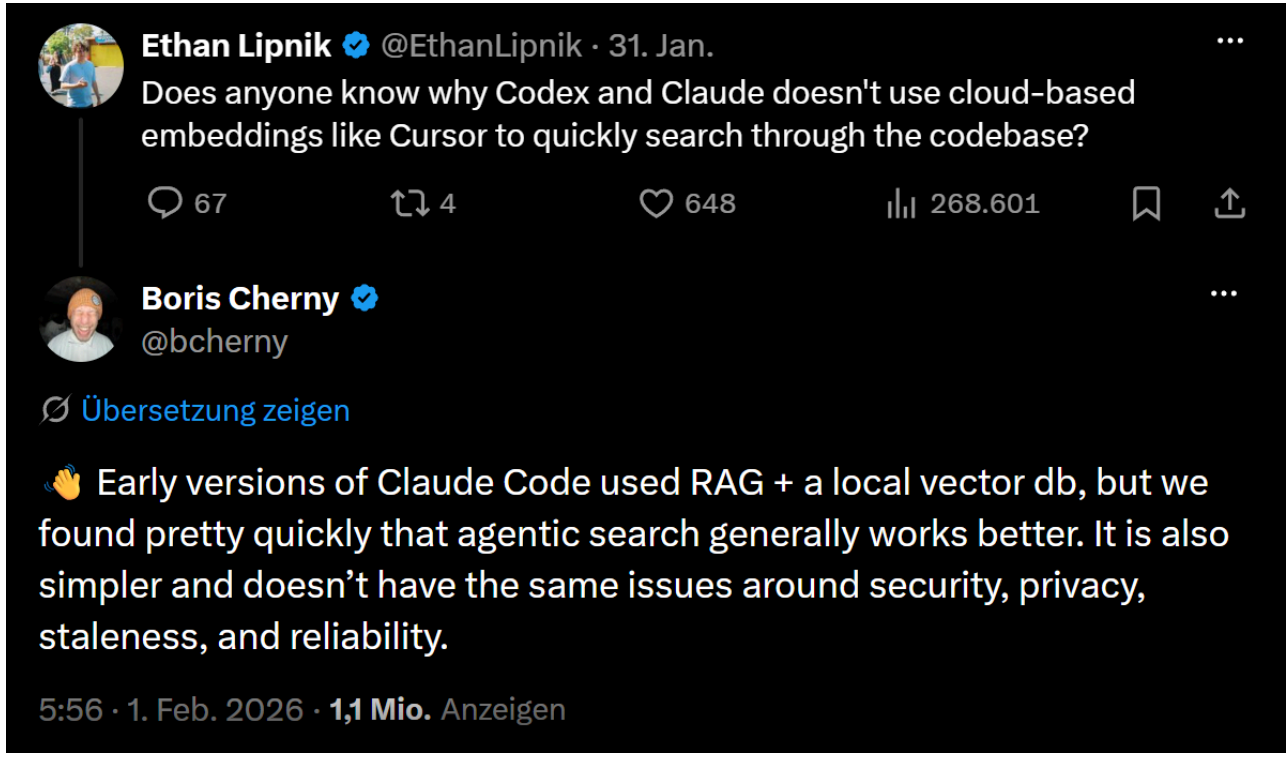
Was Boris Cherny schreibt

Frühe Versionen von Claude Code nutzten RAG mit einer lokalen Vektordatenbank. **Agentische Suche** mit `glob` und `grep` funktionierte schnell besser.

Seine Gründe

einfacher, weniger Probleme mit Sicherheit, Datenschutz, **veralteten Indizes** und Zuverlässigkeit

Im Podcast (Latent Space, 2025) räumt er ein: Die Entscheidung beruhte auf internen Erfahrungen, nicht auf einem Benchmark.



Live: Was findet grep zu unseren Fragen?

Bibliothek Samstag | Mensa Gast | Ersatzkarte | Paragraph 17 | Formular PA-12 | Raum F-201 | **krank am Klausurtag** | Auto abstellen | nachts lernen | total gestresst

Geld zu spät | wie oft Prüfung | ICE mit Ticket | Fachschaftsparty | ausdrucken | Ausweis verloren | schummeln | Internet | alles zu viel | Ticket Hamburg | § 21

PA-07 | vegan essen | Buch behalten | Prüfung anmelden | Yoga

Eigene Frage tippen und Enter …

Farbe der Fragen: umschrieben | exakte Kennung | steht nirgends | direkt

„Ich bin am Tag meiner Klausur krank. Was muss ich tun?“ richtige Datei: **pruefungsunfaehigkeit.md**

Suche nach Zeichen · grep

Treffer zählen | BM25

gesucht: "tag" "meiner" "klausur" "krank" "tun" · auch als Wortteil · Treffer gezählt

beratung.md — **10 Treffer**

Beratung und Unterstützung

bibliothek.md — **7 Treffer**

Die Bibliothek im Gebäude L hat Montag bis Freitag von 8 bis 22 Uhr geöffnet,

praxissemester.md — **4 Treffer**

Im fünften Semester arbeitet ihr mindestens 95 Präsenztage in einem

mensa.md — **3 Treffer**

Die Mensa im Gebäude M gibt Essen Montag bis Freitag von 11:15 bis 14:00 Uhr

Suche nach Bedeutung · Embeddings

Kosinus-Ähnlichkeit zur Frage · Top 4 von 48 Abschnitten · granite-embedding:278m

praxissemester.md — **0.709**

Am Ende gebt ihr einen Bericht von etwa 15 Seiten und ein Zeugnis des Unternehmens ab. Krankheitstage über fünf Tage hinaus müssen nachgeholt werden.

pruefungsunfaehigkeit.md — **0.670**

Wann gilt das? Wer an einem Prüfungstag aus gesundheitlichen Gründen nicht antreten kann oder eine Prüfung deshalb abbricht, gilt als prüfungsunfähig. Die Prüfung wird dann…

pruefungsunfaehigkeit.md — **0.663**

Nachweis Nötig ist ein ärztliches Attest, das die Prüfungsunfähigkeit am Prüfungstag bestätigt. Eine einfache Arbeitsunfähigkeitsbescheinigung reicht nicht. Das Attest muss…

pruefungsunfaehigkeit.md — **0.661**

Stark bei Kennungen, schwach bei Umschreibungen

Stärken

- **exakt:** `F-201`, `PA-12`, Funktionsnamen
- **immer aktuell:** kein Index, der veraltet
- **keine Vorbereitung:** kein Chunking, keine Vektor-DB
- **nachvollziehbar:** Treffer mit Zeilennummer
- **Rechte bleiben:** sucht mit den Rechten des Nutzers

Grenzen

- **Synonyme:** „krank" findet kein „Attest", „Auto" kein „Kfz"
- **Wortteile:** „tag" in Montag, „raum" in Prüfungszeitraum
- **Bewertung:** häufige Wörter schlagen seltene
- **Kosten:** jede Suchrunde ist ein Modellaufruf
- **Modell:** nur so gut wie die Suchbegriffe

Die Suche ist nur so gut wie die Suchbegriffe

FRAGE
Ich bin am Tag meiner Klausur krank. Was muss ich tun?

SUCHBEGRIFFE VON LLAMA3.2:3B
`Krankheit, Arzt, Medikamente, Krankenakte, Schulabsenz, Arztbescheinigung`

WAS IN DER DATEI STEHT
ärztliches **Attest**, **Prüfungsunfähigkeit**, Formular PA-07

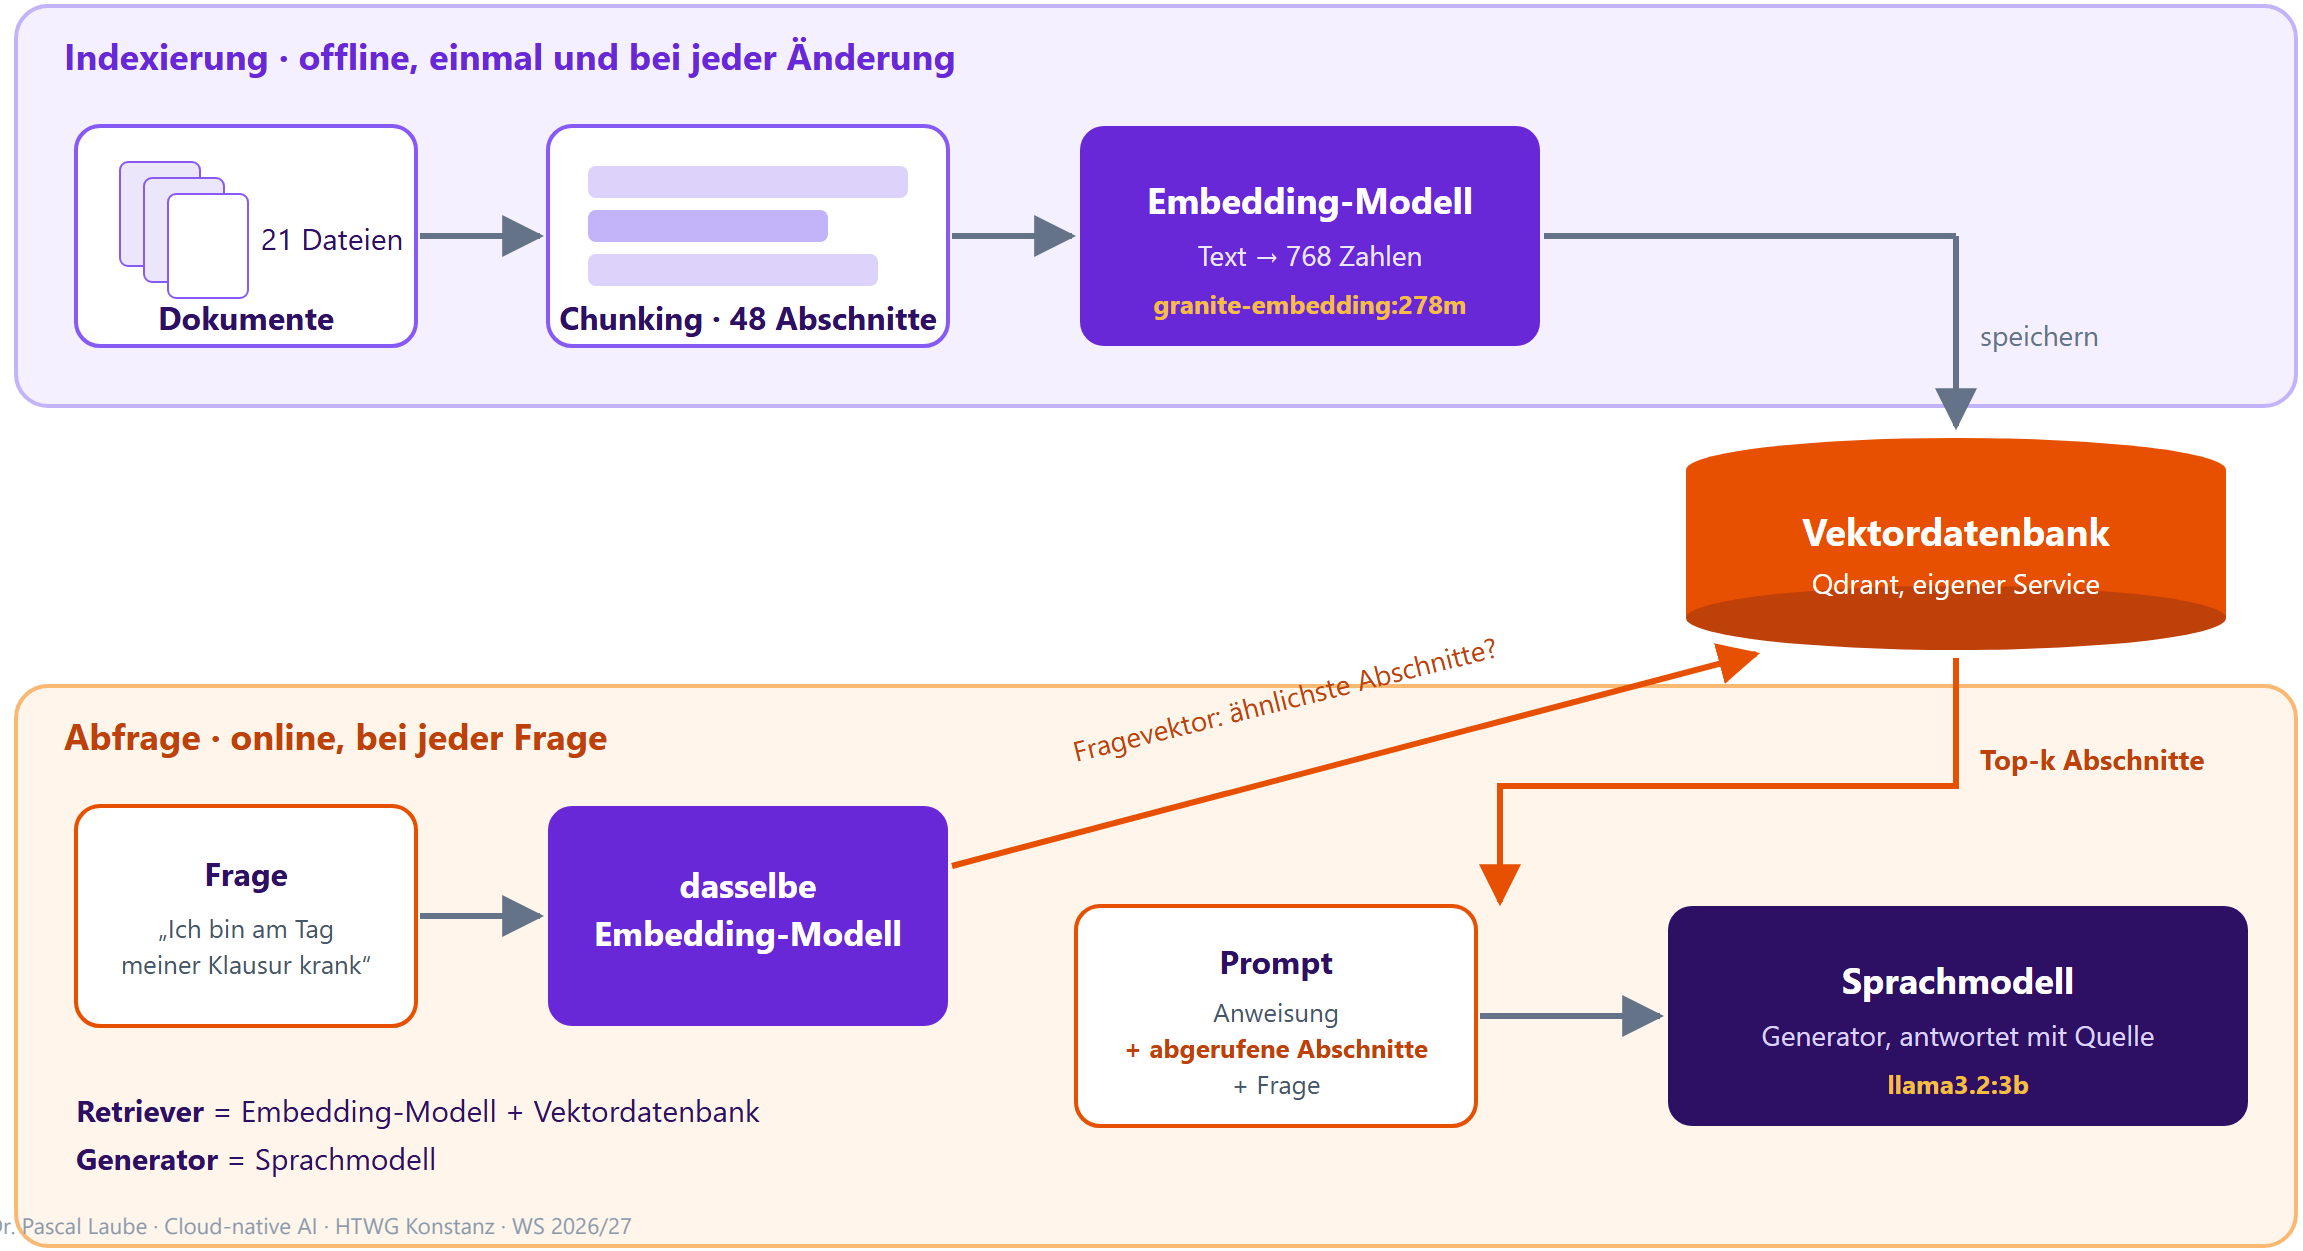
Suchbegriffe von …	richtige Datei im Kontext
den Wörtern der Frage	7 von 13
`llama3.2:3b`	8 von 13

Ein großes Modell rät bessere Begriffe und sucht nach, wenn der erste Versuch nichts bringt. **Darum funktioniert das bei Claude Code** und bei unserem 3B-Modell kaum.

2 · RAG

Retrieval-Augmented Generation: erst den Index bauen, dann nach Bedeutung suchen

RAG besteht aus zwei Abläufen, die sich die Vektordatenbank teilen



Termbasiert: BM25 ist ein klügeres grep

Ganze Wörter statt Zeichenketten, kleingeschrieben, ohne Stoppwörter.

Seltene Wörter zählen mehr: die inverse Dokumenthäufigkeit

$$\mathrm{IDF}(t) = \log \frac{N}{C(t)}$$

N = Zahl der Dokumente, C(t) = Dokumente mit Term t. BM25 dämpft zusätzlich Wiederholungen und lange Dokumente.

> Huyen: BM25 ist eine Messlatte, die schwer zu schlagen ist.

„Wer sitzt in Raum F-201?“

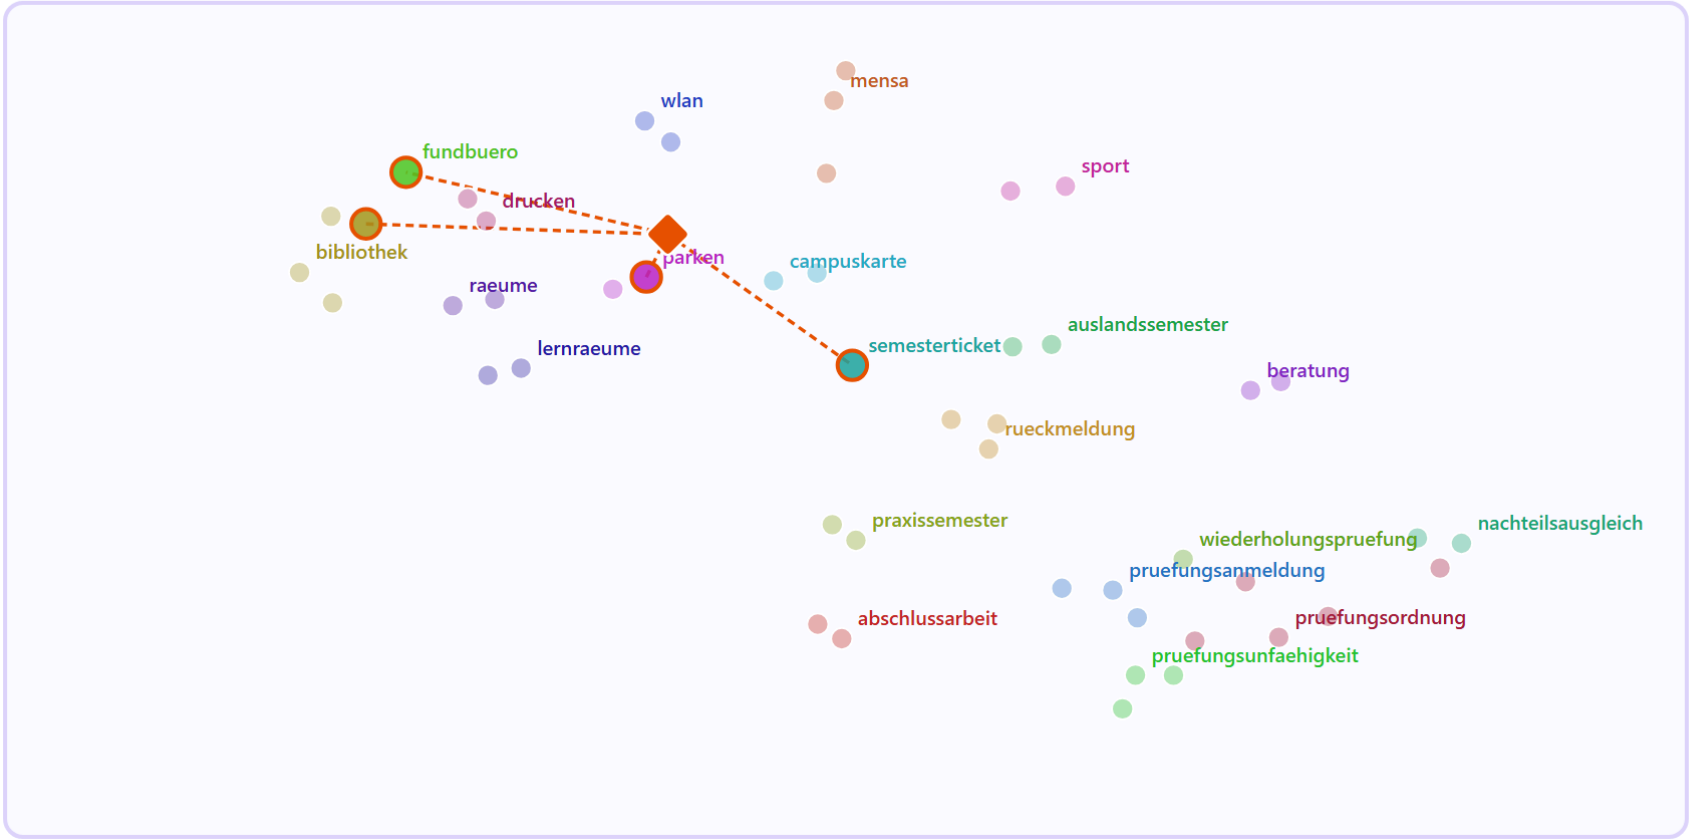


Treffer zählen: `praxissemester.md` auf Rang 4
BM25: **Rang 1**

Probiert es in der Spielwiese: oben rechts **BM25** umschalten.

Embeddings: Texte mit ähnlicher Bedeutung liegen nah beieinander

Bibliothek Samstag | Mensa Gast | Ersatzkarte | Paragraph 17 | Formular PA-12 | Raum F-201 | krank am Klausurtag | **Auto abstellen** | nachts lernen | total gestresst | Geld zu spät | wie oft Prüfung | ICE mit Ticket | Fachschaftsparty | ausdrucken | Ausweis verloren | schummeln | Internet | alles zu viel | Ticket Hamburg | § 21 | PA-07 | vegan essen | Buch behalten | Prüfung anmelden | Yoga



„Wo kann ich mein Auto abstellen und was kostet das?“

richtig: **parken.md**

`parken.md`	**0.674**
`fundbuero.md`	**0.643**
`bibliothek.md`	**0.624**
`semesterticket.md`	**0.621**

Gestrichelt: die vier ähnlichsten Abschnitte im echten Raum mit 768 Dimensionen. Die Karte drückt diesen Raum auf zwei Dimensionen zusammen (t-SNE), Abstände auf der Karte stimmen deshalb nur ungefähr.

Live: dieselbe Frage, zwei Suchen

Bibliothek Samstag | Mensa Gast | Ersatzkarte | Paragraph 17 | Formular PA-12 | Raum F-201 | krank am Klausurtag | Auto abstellen | nachts lernen | total gestresst | Geld zu spät | wie oft Prüfung | ICE mit Ticket | Fachschaftsparty | ausdrucken | Ausweis verloren | schummeln | Internet | alles zu viel | Ticket Hamburg | § 21 | PA-07 | vegan essen | Buch behalten | Prüfung anmelden | Yoga

Eigene Frage tippen und Enter …

Farbe der Fragen: umschrieben | exakte Kennung | steht nirgends | direkt

„Ich bin am Tag meiner Klausur krank. Was muss ich tun?“ richtige Datei: **pruefungsunfaehigkeit.md**

Suche nach Zeichen · grep

Treffer zählen | BM25

gesucht: "tag" "meiner" "klausur" "krank" "tun" · auch als Wortteil · Treffer gezählt

beratung.md — **10 Treffer**

Beratung und Unterstützung

bibliothek.md — **7 Treffer**

Die Bibliothek im Gebäude L hat Montag bis Freitag von 8 bis 22 Uhr geöffnet,

praxissemester.md — **4 Treffer**

Im fünften Semester arbeitet ihr mindestens 95 Präsenztage in einem

mensa.md — **3 Treffer**

Die Mensa im Gebäude M gibt Essen Montag bis Freitag von 11:15 bis 14:00 Uhr

Suche nach Bedeutung · Embeddings

Kosinus-Ähnlichkeit zur Frage · Top 4 von 48 Abschnitten · granite-embedding:278m

praxissemester.md — **0.709**

Am Ende gebt ihr einen Bericht von etwa 15 Seiten und ein Zeugnis des Unternehmens ab. Krankheitstage über fünf Tage hinaus müssen nachgeholt werden.

pruefungsunfaehigkeit.md — **0.670**

Wann gilt das? Wer an einem Prüfungstag aus gesundheitlichen Gründen nicht antreten kann oder eine Prüfung deshalb abbricht, gilt als prüfungsunfähig. Die Prüfung wird dann…

pruefungsunfaehigkeit.md — **0.663**

Nachweis Nötig ist ein ärztliches Attest, das die Prüfungsunfähigkeit am Prüfungstag bestätigt. Eine einfache Arbeitsunfähigkeitsbescheinigung reicht nicht. Das Attest muss…

pruefungsunfaehigkeit.md — **0.661**

Das Embedding-Modell muss zur Sprache passen

Embedding-Modell	Sprachen	richtige Datei in Top 4
`granite-embedding:278m`	mehrsprachig	**12 von 13**
`embeddinggemma`	mehrsprachig	12 von 13
`qwen3-embedding:0.6b`	mehrsprachig	12 von 13
`nomic-embed-text`	vor allem Englisch	**10 von 13**

Unsere 13 Testfragen mit bekannter Quelle, alle Modelle lokal in Ollama.

nomic verliert genau die Umschreibungen

krank am Klausurtag, Auto abstellen, total gestresst

Alle verlieren „Raum F-201“

Eine Kennung hat kaum Bedeutung. Huyen: Ein Fehlercode wie `EADDRNOTAVAIL (99)` geht in der Vektorsuche unter.

Termbasiert und embeddingbasiert machen verschiedene Fehler

	Termbasiert (grep, BM25)	Embeddingbasiert
findet	Kennungen, Namen, Code exakt	Bedeutung, auch ohne gemeinsame Wörter
scheitert an	Synonymen, Umschreibungen	Kennungen, seltenen Begriffen
Vorbereitung	keine (grep) oder invertierter Index (BM25)	Chunking, Embedding-Modell, Vektordatenbank
Aktualität	sofort	erst nach neuer Indexierung
Stellschrauben	wenige	Modellwahl, Chunking, Finetuning
Kosten	sehr gering	Rechenzeit beim Indexieren, eigener Service

Folge: In der Praxis kombiniert man beide. Das heißt **hybride Suche**.

Chunking: Wo man schneidet, entscheidet, was man findet

Abschnittsgröße 160 Zeichen Überlappung 0 Zeichen an Überschriften trennen

5 Abschnitte. Der Satz mit der Frist ist zerschnitten. Kein Abschnitt enthält ihn ganz: Ein Abschnitt kennt die Frist, ein anderer, wofür sie gilt.

```
# Rücktritt aus gesundheitlichen Gründen

## Wann gilt das?
Wer an einem Prüfungstag aus gesundheitlichen Gründen nicht antreten kann
oder eine Prüfung deshalb abbricht, gilt als prüfungsunfähig. Die Prüfung
wird dann nicht als Fehlversuch gewertet, wenn der Grund rechtzeitig
nachgewiesen wird.

## Nachweis
Nötig ist ein ärztliches Attest, das die Prüfungsunfähigkeit am Prüfungstag
bestätigt. Eine einfache Arbeitsunfähigkeitsbescheinigung reicht nicht.
Das Attest muss innerhalb von drei Werktagen nach dem Prüfungstermin beim
Prüfungsamt eingehen, zusammen mit dem Formular PA-07
„Antrag auf Anerkennung der Prüfungsunfähigkeit“.

## Danach
Ihr werdet automatisch zum nächsten regulären Termin angemeldet.
```

Hybride Suche, Reranking und Contextual Retrieval

Hybride Suche mit RRF

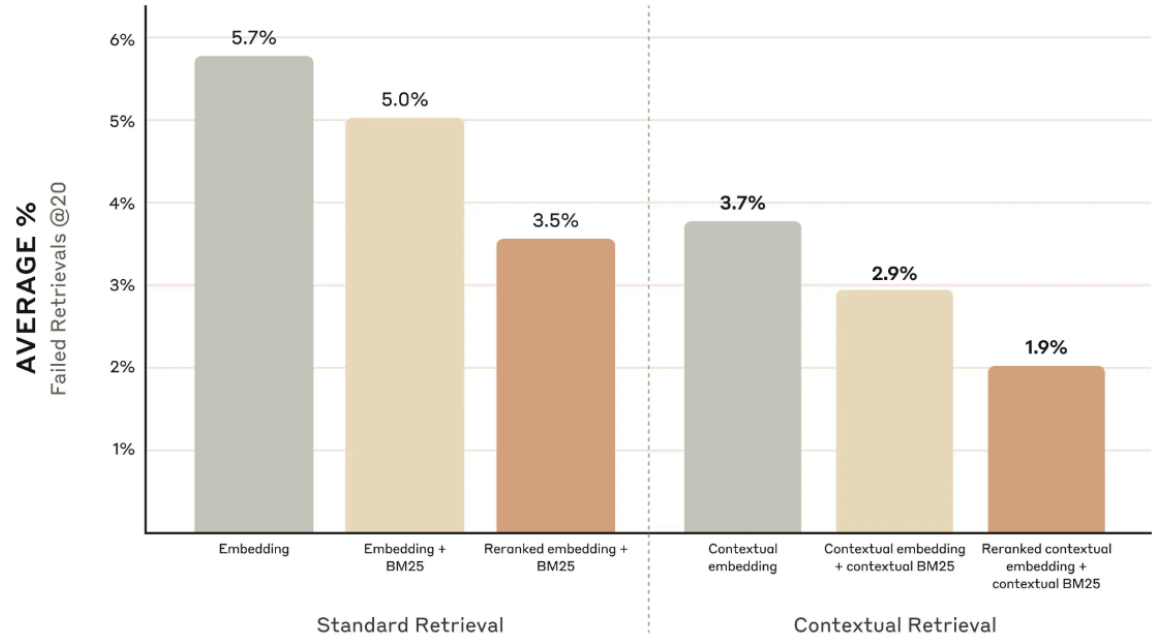
BM25 und Embeddings parallel, Ranglisten zusammenführen:
Score(D) = Σ 1 / (60 + $Rang_i$(D))

Reranking

Schnelle Suche liefert 50 Kandidaten, ein genaueres Modell sortiert neu.

Contextual Retrieval

Ein LLM schreibt jedem Abschnitt einen Kontextsatz voran. Fehlerrate von 5,7 auf **1,9** % (Anthropic, 2024).



Reranked Contextual Embedding and Contextual BM25 reduces the top-20-chunk retrieval failure rate by 67%.

Retrieval misst man getrennt von der Antwort

Context Precision

Welcher Anteil der abgerufenen Abschnitte ist relevant?

Context Recall

Welcher Anteil der relevanten Abschnitte wurde abgerufen? In Produktion schwer, mit festen Testfragen einfach.

```
Frage                          Typ          datei   rag
Wer sitzt in Raum F-201?       kennung       · ·    · ·
Ich bin ... krank              umschrieben   · ·    K A
Wie oft darf ich ...           umschrieben   · A    K A
```

K = richtige Datei im Kontext, **A** = Antwort richtig. Ausgabe von `vergleich_wissen.py` aus Übung 2.

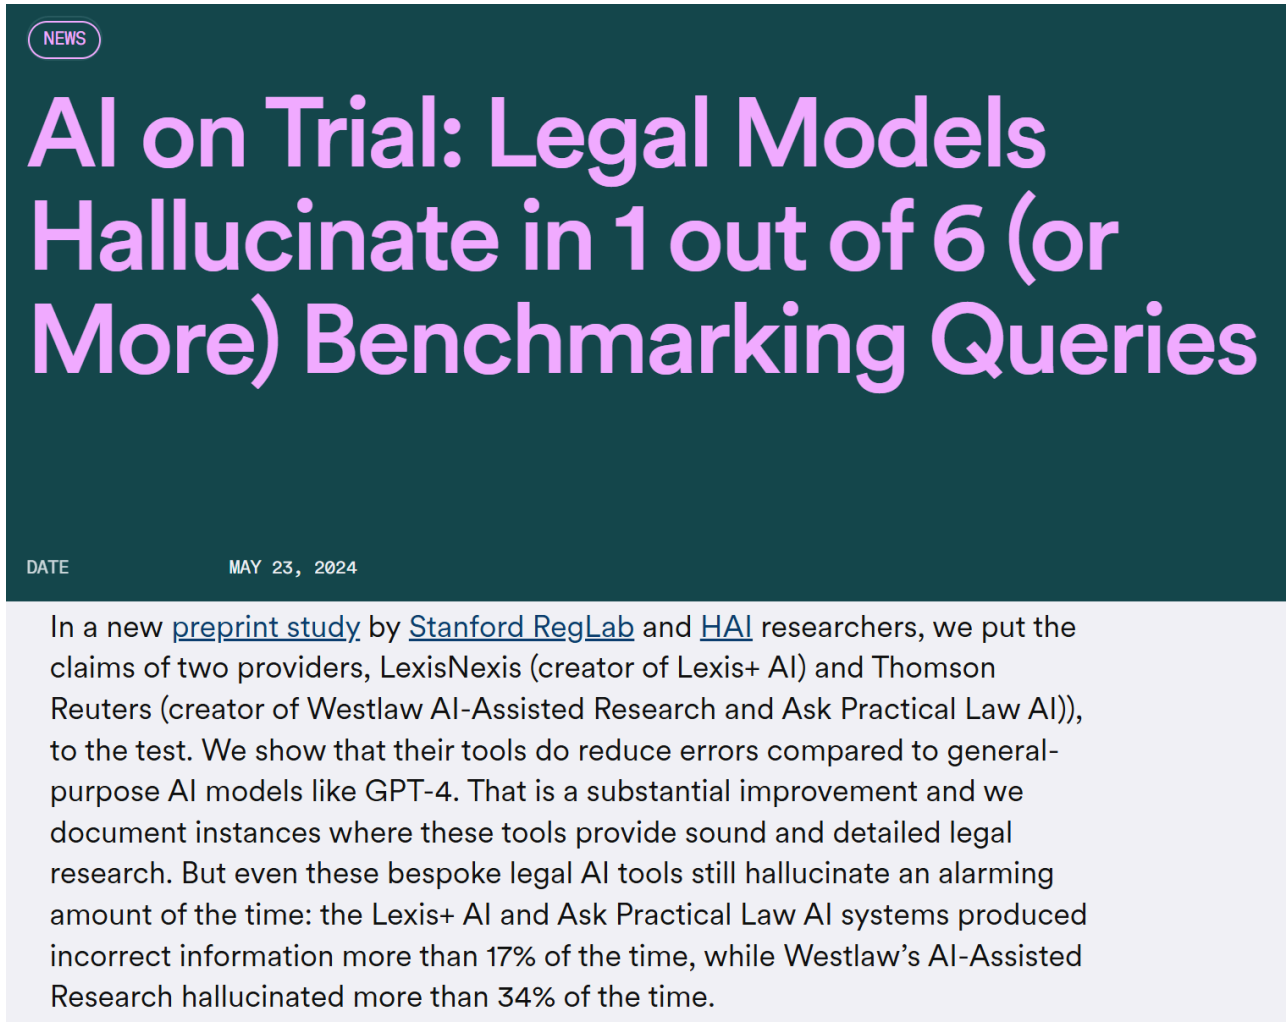
Frage an euch: Was bedeutet eine Zeile mit **K**, aber ohne **A**? Und was eine mit **A**, aber ohne **K**?

RAG senkt Halluzinationen, verhindert sie aber nicht

Stanford RegLab und HAI prüften 2024 juristische Recherchewerkzeuge, die mit „halluzinationsfreien“ Zitaten warben. Alle beruhen auf RAG.

> **17 bis 33 % falsch**
>
> Besser als GPT-4 allein, aber weit von „halluzinationsfrei“ entfernt (Magesh et al., 2024).

Fehler entstehen an jeder Stelle: falsches Dokument gefunden, richtiges falsch gelesen, eigenes Wissen beigemischt.



Google empfiehlt Klebstoff auf der Pizza

Mai 2024: Die AI Overviews in der Google-Suche stützen sich auf einen ironischen Forenbeitrag und auf Satire.

Die Suche fand, was da war

Zu „Wie viele Steine soll ich essen?“ gab es fast nur Satire. Google nennt das eine **Datenlücke**.

RAG macht ein Modell nicht wahrhaftig, sondern abhängig von seinen Quellen. Quelle nennen und „Dazu habe ich keine Information“ erlauben.

AI Overviews: About last week

May 30, 2024
5 min read

Elizabeth Reid
VP, Search

Share

There isn't much web content that seriously contemplates that question, either. This is what is often called a “data void” or “information gap,” where there’s a limited amount of high quality content about a topic. However, in this case, there is satirical content on this topic ... that also happened to be republished on a geological software provider’s website. So when someone put that question into Search, an AI Overview appeared that faithfully linked to one of the only websites that tackled the question.

In other examples, we saw AI Overviews that featured sarcastic or troll-y content from discussion forums. Forums are often a great source of authentic, first-hand information, but in some cases can lead to less-than-helpful advice, like using glue to get cheese to stick to pizza.

3 · Wissen als Service

Und wann ihr welchen Weg nehmt

Die Wissensbasis wird ein eigener Baustein

Heute in Compose (Übung 2):

```
qdrant:
  image: qdrant/qdrant:v1.20.0
  volumes:
    - qdrant-daten:/qdrant/storage
```

Embeddings aus Ollama, Index im Volume.

Komponente	in Kubernetes (VL 9)
Vektordatenbank	StatefulSet mit Volume
Embedding-Modell	Deployment oder Sidecar
unser Python-Code	zustandsloses Deployment
Indexierung	Job oder CronJob

Nach Huß und Zonca, Tabelle 8-1

Drei neue Pflichten: Index aktuell halten · für Indexierung und Abfrage dasselbe Embedding-Modell nutzen · Zugriffsrechte selbst prüfen, denn der Index enthält alles

Unsere Messung: drei Wege, 14 Testfragen

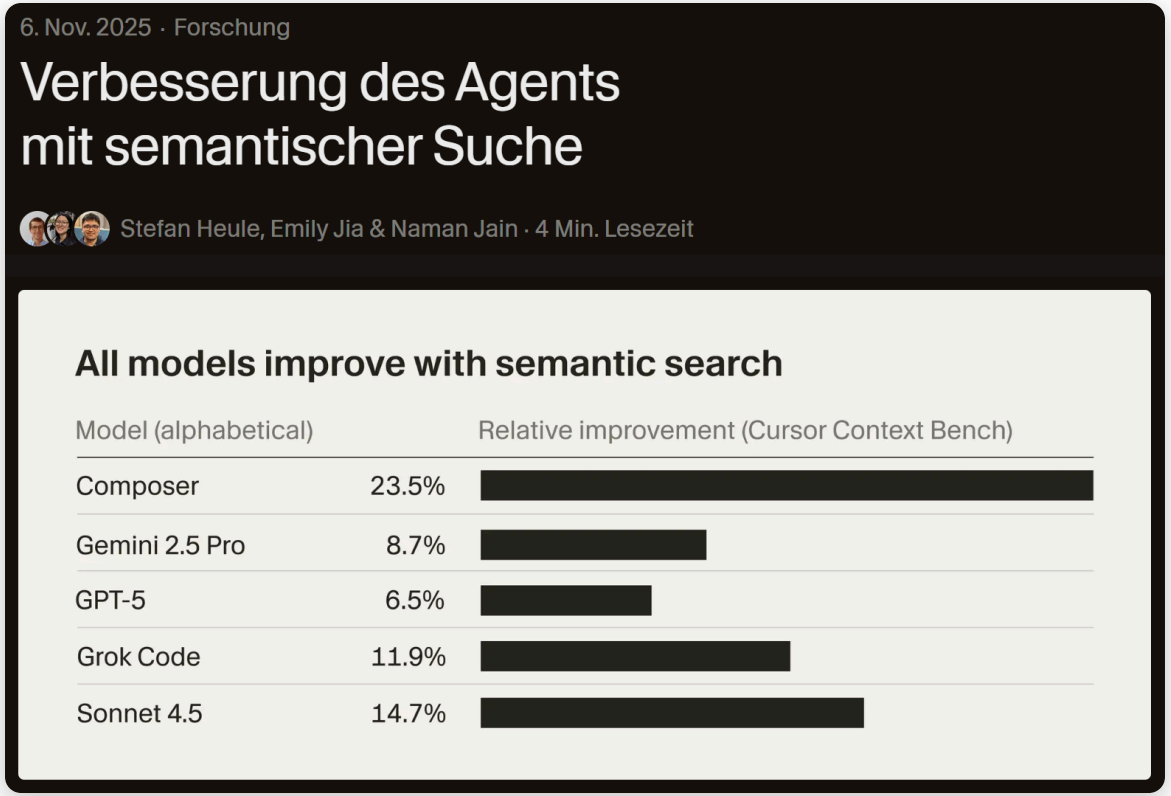
Variante	Kontext richtig	Antwort richtig	Tokens (Ø)	Dauer (Ø)
alles in den Kontext	13 / 13	**14 / 14**	3.904	8,1 s
grep mit den Wörtern der Frage	7 / 13	9 / 14	682	9,4 s
Modell wählt Suchbegriffe, dann grep	8 / 13	10 / 14	602	11,0 s
RAG, ein Abschnitt pro Datei	12 / 13	12 / 14	891	11,6 s
RAG, an Überschriften zerlegt	12 / 13	13 / 14	**555**	8,6 s

Klein? Alles mitgeben.
Siebenmal so viele Tokens, dafür nichts verpasst.

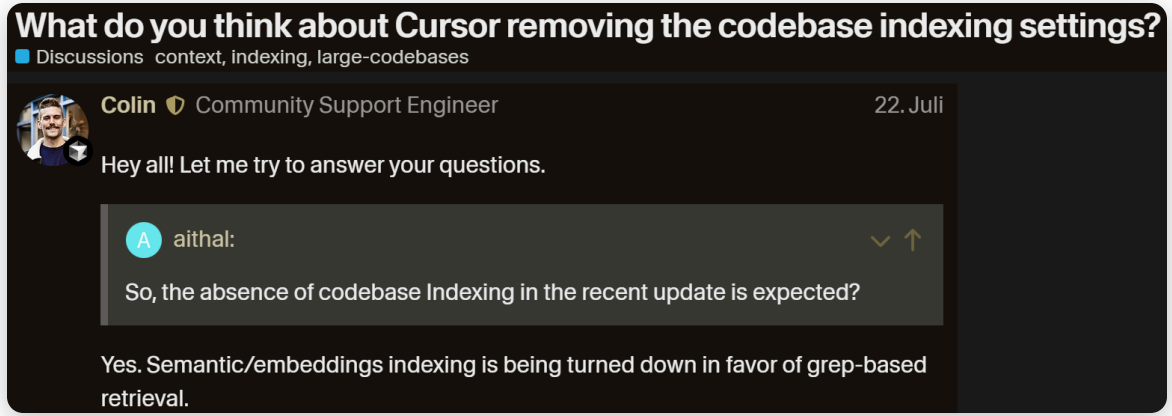
grep
scheitert an Umschreibungen, das 3B-Modell sucht schlecht

RAG
scheitert an der Kennung F-201, Chunking spart 38 % Tokens

Cursor: erst Embeddings, dann zurück zu grep



November 2025: semantische Suche verbessert den Agenten im Mittel um 12,5 %.



Juli 2026: Der Embedding-Index wird abgeschaltet. Begründung eines Cursor-Mitarbeiters: Die Modelle sind inzwischen so gut im Suchen mit grep, dass die semantische Suche kaum noch half. Embeddings des Codes werden nicht mehr auf Cursors Servern gespeichert.

Wann was?

Wenn …	… dann
das Wissen in den Kontext passt und sich selten ändert	**alles mitgeben**, mit Prompt Caching
Kennungen, Code und exakte Begriffe zählen, Dateien sich oft ändern	**File-based Retrieval**, am besten mit starkem Modell, das nachsucht
Nutzer in eigenen Worten fragen und die Wissensbasis groß ist	**RAG** mit Embeddings
beides vorkommt, wie fast immer	**hybrid**: BM25 und Embeddings, dazu Reranking
Antworten nachprüfbar sein müssen	Quelle ausgeben und „keine Information“ erlauben, immer

Tut das Einfachste, das funktioniert.

Für 21 Dateien ist das gar keine Suche. Für Code oft grep. Für Tausende Dokumente RAG, meist hybrid.

Jetzt ihr: 30 Minuten Retrieval-Labor

Öffnet **„VL 04 · Retrieval-Labor“** auf der Kursseite. Arbeitet zu zweit, notiert eure Antworten direkt im Labor.

Übung 2 ab 11:30: Teil 4, Abgabe Montag, 02.11., 23:59

4.1 · Alles mitgeben

Tokens, Dauer und der Prompt-Cache

4.2 · Dateisuche

TODO 4a: Treffer zählen, warum F-201 verloren geht

4.3 · RAG

TODO 4b: Chunking, Index in Qdrant, Dashboard

4.4 · Vergleichen

Tabelle nach Fragetyp: wer gewinnt wann?

4.5 · Verbessern

BM25, hybrid, besseres Embedding oder bessere Suchbegriffe, gemessen

Neu im Starter

`Uebung_2_Teil4.zip` in `uebung_2/` entpacken

Vorher zu Hause: `docker compose run --rm --build app alles.py "Test"` lädt Qdrant und das Embedding-Modell (ca. 560 MB). Im WLAN der Hochschule dauert das.

Quellen

- Chip Huyen: *AI Engineering. Building Applications with Foundation Models.* O'Reilly, 2025, Kapitel 6
- Roland Huß, Daniele Zonca: *Generative AI on Kubernetes.* O'Reilly, 2026, Kapitel 6 und 8
- Anthropic: *Effective context engineering for AI agents*, 2025 · *Introducing Contextual Retrieval*, 2024
- Patrick Lewis et al.: *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.* NeurIPS, 2020
- Stephen Robertson, Hugo Zaragoza: *The Probabilistic Relevance Framework: BM25 and Beyond.* 2009
- Gordon V. Cormack et al.: *Reciprocal Rank Fusion outperforms Condorcet and individual Rank Learning Methods.* SIGIR, 2009
- Varun Magesh et al.: *Hallucination-Free? Assessing the Reliability of Leading AI Legal Research Tools.* 2024
- Fälle: Boris Cherny auf X, 01.02.2026 · Latent Space, *Claude Code*, 2025 · Cursor Blog, *Improving agent with semantic search*, 06.11.2025 · Cursor Community Forum, 21./22.07.2026 · Elizabeth Reid, Google, *AI Overviews: About last week*, 30.05.2024 · Stanford HAI, 23.05.2024

Ein Modell weiß nur, was im Kontext steht. Eure Aufgabe ist, das Richtige hineinzulegen.

Nächste Woche: Agenten und Werkzeuge. Was passiert, wenn das Modell selbst entscheidet, wonach es sucht?